

Diagnóstico de generalização do pipeline GLSTM

Por que a previsão converge para a média — ou para uma média ponderada

Auditoria do caminho realmente executado por `src/run_experiment.py`, incluindo dados, cronologia, janelas, normalização, grafo, arquitetura GLSTM, função objetivo, treinamento, checkpoint e inferência.

Configuração de referência: `Experiments/run_experiment/glstm_sweep_20260715_120845`

Data da auditoria: 15 de julho de 2026

Escopo: diagnóstico e recomendações. Nenhuma alteração funcional foi aplicada ao código de treinamento.

Sumário

1	Conclusão executiva	1
2	Escopo, evidência e definição de generalização	2
2.1	Arquivos e artefatos examinados	2
2.2	O que “dados novos” significa neste runner	2
3	Rastreio do pipeline executado	3
3.1	Fluxo efetivo	3
3.2	Configuração atual	3
4	Integridade temporal e estatística dos dados	4
4.1	Pontos que passaram na auditoria	4
4.2	Distribuição do alvo e drift	4
4.3	Redundância das janelas	4
5	Evidência quantitativa do colapso	5
5.1	Resultado da configuração atual	5
5.2	Baselines ajustados somente no treino	6
5.3	A regressão à média sob MSE comum	6
6	Por que a loss produz uma média ponderada	7
6.1	Derivação	7
6.2	A seleção do checkpoint reforça o desalinhamento	7
7	O grafo aprendível está promovendo oversmoothing	8
7.1	Mecanismo no código	8
7.2	Evidência no checkpoint	8
8	Limitação informacional e arquitetural	9
8.1	O input não é uma previsão meteorológica de $D+1-D+5$	9
8.2	Head direto e gargalo comum	10
8.3	A natureza de uma previsão pontual	10
9	Problemas secundários e observabilidade	10
10	Hipóteses descartadas ou rebaixadas	11
11	Plano recomendado	11
11.1	Prioridade P0 — tornar a conclusão mensurável	11
11.2	Prioridade P1 — separar objetivo, horizonte e grafo	12

11.3 Prioridade P1 — corrigir o grafo aprendível	12
11.4 Prioridade P2 — fornecer informação realmente preditiva	12
11.5 Prioridade P2 — objetivo adequado à precipitação	13
11.6 Critérios de aceitação	13
12 Resposta direta	13
A Trilha de evidências reproduzíveis	14
B Limitações da auditoria	14

1 Conclusão executiva

Diagnóstico principal. O comportamento observado não é, no estado atual, um caso clássico de rede que ajusta muito bem o treino e falha apenas em dados novos. O R^2 ordinário já é negativo no treino. A rede aprende modestamente a função objetivo configurada, mas essa função objetivo, combinada com pouco sinal preditivo para D+2–D+5, favorece justamente uma previsão quase constante. Com MSE comum, essa constante é a média. Com a `quantile_mse` atual, ela é uma **média ponderada alta**, aproximadamente 15,29 mm.

Os dados e o alinhamento temporal foram verificados de ponta a ponta. Não foram encontrados NaNs, infinitos, datas faltantes, troca de eixos ou vazamento de alvos entre treino, validação e teste. O contrato efetivo é

$$X \in \mathbb{R}^{B \times 35 \times 62 \times 25} \longrightarrow \hat{y} \in \mathbb{R}^{B \times 5 \times 62},$$

compatível com $y \in \mathbb{R}^{B \times 5 \times 62}$. Os scalers são ajustados somente no treino. Assim, o colapso não é explicado por um erro básico de shape ou cronologia.

As causas mais importantes, em ordem, são:

1. **Crítica — objetivo desalinhado.** A função chamada `QuantileMSELoss` não é uma quantile loss do tipo pinball. Ela é uma MSE por faixas do alvo. Com Q90 e pesos automáticos, cada observação extrema recebe aproximadamente nove vezes o peso de uma observação comum. O ótimo sem sinal deixa de ser 4,58 mm e passa a ser 15,29 mm.
2. **Crítica — densificação do grafo aprendível.** Com `LOCK_TOPOLOGY=False`, todos os pares de estações tornam-se parametrizados. O mesmo `weight_decay=0.005` é aplicado aos logits da adjacência; levar um logit negativo para zero significa levar a probabilidade de uma não-aresta para 0,5. O checkpoint terminou com 69,0% da massa normalizada em ligações que não existiam no KNN inicial.
3. **Alta — informação insuficiente para horizontes longos.** A entrada contém somente agregados meteorológicos *passados*. Não há NWP futuro alinhado a cada lead, calendário, altitude ou embedding de estação; vento está desligado. D+1 ainda contém algum sinal, mas a variabilidade prevista cai rapidamente até D+5.
4. **Alta — compressão e suavização.** O mesmo estado oculto final de dimensão 32 produz os cinco leads; a mistura espacial é aplicada dentro da recorrência a cada um dos 35 passos. Isso favorece *oversmoothing* temporal e espacial.
5. **Média — avaliação incompleta.** Há somente um corte temporal, nenhuma validação rolling-origin, nenhum holdout espacial e nenhum baseline climatológico integrado ao runner. Além disso, alguns arquivos misturam métricas padronizadas e métricas em mm.

No teste da configuração atual, a chuva real tem média 4,447 mm e desvio-padrão 10,191 mm. A previsão tem média 13,635 mm e desvio-padrão 3,713 mm. O resultado é viés de +9,188 mm, $R^2 = -0,803$ e MSE físico de 187,24 mm². Uma climatologia estação–mês ajustada apenas no treino obtém MSE de 103,29 mm².

2 Escopo, evidência e definição de generalização

2.1 Arquivos e artefatos examinados

O caminho de execução foi seguido a partir de `src/run_experiment.py:120`, sem inferir o comportamento a partir de notebooks antigos. Os principais pontos auditados foram:

- configuração e orquestração: `src/run_experiment.py:46–src/run_experiment.py:311`;
- dataset datado: `src/Data/temporal_dataset.py:129–src/Data/temporal_dataset.py:567`;
- agregações ERA5: `src/Data/feature_extraction.py:173–src/Data/feature_extraction.py:257` e `src/Data/feature_extraction.py:411–src/Data/feature_extraction.py:495`;
- topologia: `src/Graph/graph_related_utils.py:250–src/Graph/graph_related_utils.py:278`;
- GLSTM: `src/Models/model.py:129–src/Models/model.py:306`;
- loss e construção do modelo: `src/Training/experiment_runner.py:95–src/Training/experiment_runner.py:245`;
- treino, validação e checkpoint: `src/Training/Training_Routines.py:40–src/Training/Training_Routines.py:350`;
- inversão de escala e métricas físicas: `src/Evaluation/experiment_outputs.py:118–177`;
- exportação das previsões: `src/Evaluation/experiment_outputs.py:610–655`.

Foi usada como reprodução principal a execução `glstm_sweep_20260715_120845`, concluída com a configuração que está no topo do runner. Ela produziu 576.910 pares alvo–previsão no teste. Runs anteriores foram usados somente como ablação ou evidência histórica, e são identificados explicitamente quando aparecem.

2.2 O que “dados novos” significa neste runner

O runner mede apenas **generalização temporal para datas futuras nas mesmas 62 estações**. A função `chronological_split` corta o eixo do tempo, mas preserva todos os nós nos três blocos. Portanto:

- o teste é válido para novos dias nas posições já conhecidas;
- não existe teste de estação, região ou célula ERA5 nunca vista;
- o modelo possui uma adjacência 62×62 e não aceita um novo nó sem reconstrução;
- para alegar generalização espacial seria necessário um holdout por estação/região e uma arquitetura indutiva para reconstruir as arestas.

Há ainda uma distinção de domínio importante: o catálogo INMET fornece nomes e coordenadas, mas as séries de entrada e o alvo são valores ERA5 amostrados no ponto de grade mais próximo. Em `src/Data/temporal_dataset.py:275–src/Data/temporal_dataset.py:294`, o próprio canal `tp` do ERA5 origina `y`. Observações pluviométricas dos CSVs INMET não entram no alvo. Assim, desempenho em uma estação real não é medido por este teste; seria uma transferência ERA5→INMET adicional.

3 Rastreo do pipeline executado

3.1 Fluxo efetivo

Etapa	Operação confirmada	Evidência principal
1	Lê o catálogo, filtra RS e retém nomes, latitude e longitude.	<code>run_experiment.py</code> : 176-179; <code>feature_extraction.py</code> : 454-467
2	Abre caches diários ERA5 e amostra a grade na coordenada mais próxima de cada estação.	<code>temporal_dataset.py</code> : 180-192, 248-376
3	Concatena 25 features e usa <code>tp</code> como alvo diário.	$X = [9497, 62, 25]$, $y = [9497, 62]$
4	Faz split cronológico no eixo bruto antes das janelas.	<code>temporal_dataset.py</code> : 379-408
5	Cria janelas separadamente: $[D - 34, \dots, D] \mapsto [D + 1, \dots, D + 5]$.	<code>temporal_dataset.py</code> : 411-486
6	Ajusta <code>StandardScaler</code> de features e alvo somente nas janelas de treino.	<code>temporal_dataset.py</code> : 508-555
7	Converte para Torch e cria <code>DataLoaders</code> ; somente treino é embaralhado.	<code>temporal_dataset.py</code> : 558-567; <code>prepare_data.py</code> : 192-229
8	Constrói KNN, GLSTM, loss, Adam, scheduler e early stopping.	<code>run_experiment.py</code> : 214-277
9	Avalia o melhor checkpoint, coleta previsões e desfaz o scaler para os CSVs/gráficos.	<code>run_experiment.py</code> : 279-308

3.2 Configuração atual

Componente	Valor efetivo
Período	01/01/2000 a 31/12/2025; 9.497 dias
Nós e features	62 nomes de estação; 25 canais ERA5
Janela e horizonte	35 dias passados; saídas $D+1$ a $D+5$
Split	60% treino, 20% validação, 20% teste
Escala	<code>StandardScaler</code> global por feature e <code>StandardScaler</code> global do alvo
Grafo	KNN $k = 2$; <code>LEARN_ADJ=True</code> ; <code>LOCK_TOPOLOGY=False</code>
GLSTM	hidden 32; 1 camada; dropout 0,3; saída linear direta de 5 leads
Otimização	Adam; LR 10^{-3} ; weight decay 5×10^{-3} ; clipping 1
Seleção	até 100 épocas; paciência 10; menor loss ponderada de validação
Loss	<code>quantile_mse</code> ; Q90; pesos inversos à frequência; máximo 20

4 Integridade temporal e estatística dos dados

4.1 Pontos que passaram na auditoria

Não foi encontrado vazamento temporal ou desalinhamento do target. Foram verificados 9.497 timestamps diários consecutivos, sem duplicatas, e finitude de 14.720.350 valores de X e 588.814 valores de y . O canal histórico tp coincide com y no mesmo dia, porém somente dias até D entram no input; os alvos começam em $D + 1$.

Os intervalos brutos e as primeiras datas-alvo após o warm-up são:

Bloco	Intervalo bruto	Primeiro alvo	Janelas
Treino	01/01/2000–07/08/2015	05/02/2000	5.659
Validação	08/08/2015–18/10/2020	12/09/2015	1.860
Teste	19/10/2020–31/12/2025	23/11/2020	1.861

Os scalers e os limiares da loss são calculados somente com treino. A interseção de tempo e estações é feita antes do split, e a conversão a tensor ocorre depois da preservação das datas em xarray. Esses pontos são adequados.

4.2 Distribuição do alvo e drift

Estatística física	Treino	Teste
Média (mm)	4,580	4,447
Mediana (mm)	0,299	0,221
Desvio-padrão (mm)	9,745	10,191
P90 (mm)	15,202	14,474
P99 (mm)	47,018	50,107
Máximo (mm)	184,666	184,945
Fração $\leq 0,1$ mm	42,37%	44,41%

O teste possui cauda levemente mais pesada, mas não há um drift grosseiro: média e escala são próximas e a maior mudança média entre features, medida na escala do treino, foi 0,077 desvio-padrão. Além disso, o R^2 de treino já é negativo. Portanto, distribuição futura diferente não é a explicação principal.

4.3 Redundância das janelas

Janelas consecutivas compartilham 34 de 35 dias de input (97,1%) e 4 de 5 dias de alvo (80%). As 5.659 janelas de treino contêm 198.065 posições-dia de input, mas apenas 5.693 dias distintos nessas posições. Um mesmo alvo central aparece em até cinco amostras.

Isso não cria leakage entre splits, porém cria pseudorreplicação, reduz o tamanho amostral efetivo e torna a incerteza dos resultados muito maior do que a contagem de janelas sugere. O scaler e os quantis também ponderam repetidamente os dias centrais. A avaliação deve usar blocos temporais e rolling-origin, não interpretar cada janela como observação independente.

5 Evidência quantitativa do colapso

5.1 Resultado da configuração atual

Todas as métricas desta seção foram recalculadas no espaço físico a partir de `test_predictions_by_lead_day.csv`. O arquivo `test_metrics.json` contém MSE e MAE na escala padronizada quando `NORMALIZE_TARGET=True`; ele não deve ser comparado diretamente com valores em mm.

Lead	$\bar{y}$ mm	$\hat{\bar{y}}$	$s_{\hat{y}}/s_y$	Corr.	Inclinação	Viés mm	R^2
D+1	4,436	11,525	0,614	0,363	0,223	+7,089	-0,416
D+2	4,445	13,898	0,328	0,180	0,059	+9,453	-0,850
D+3	4,452	14,186	0,239	0,131	0,031	+9,734	-0,906
D+4	4,454	14,135	0,199	0,118	0,024	+9,681	-0,894
D+5	4,448	14,432	0,166	0,120	0,020	+9,985	-0,947

O padrão é inequívoco: a média prevista sobe para a região 14–15 mm e o desvio-padrão desaparece conforme o lead aumenta. Em D+5, a inclinação da regressão $\hat{y} = \alpha + \beta y$ é apenas 0,020; isto é, elevar a chuva real em 50 mm altera a previsão em aproximadamente 1 mm.

No agregado dos cinco leads:

- média real 4,447 mm versus média prevista 13,635 mm;
- desvio real 10,191 mm versus desvio previsto 3,713 mm;
- correlação 0,196 e inclinação 0,071;
- viés +9,188 mm, MAE 12,105 mm, MSE 187,241 mm² e $R^2 = -0,803$;
- 44,4% dos alvos são $\leq 0,1$ mm, mas apenas 0,022% das previsões;
- o modelo prevê mais de 10 mm em 88,5% dos casos; a precisão desse evento é somente 15,2%; nenhuma previsão supera 50 mm.




Figura 1: Run atual. Em D+5, a série prevista permanece próxima de 14 mm enquanto a chuva real alterna entre dias secos e picos. O scatter mostra forte compressão vertical.

5.2 Baselines ajustados somente no treino

Preditor no teste	MSE mm ²	RMSE mm	MAE mm	R^2	Viés mm
GLSTM atual	187,241	13,684	12,105	-0,803	+9,188
Média global de treino	103,884	10,192	6,139	-0,000	+0,135
Média por estação	103,470	10,172	6,106	0,004	+0,135
Climatologia estação-mês	103,286	10,163	6,094	0,006	+0,146
Zero	123,640	11,119	4,447	-0,190	-4,447
Persistência no fim da janela	192,750	13,883	6,910	-0,856	-0,019
Média ponderada Q90 de treino	221,316	14,877	13,697	-1,131	+10,837

A GLSTM atual tem MSE 81,3% maior que a climatologia estação-mês. A persistência tem MSE alto para chuva diária, mas ainda obtém MAE muito menor que a GLSTM. O baseline zero obtém MAE de 4,447 mm porque há muitos dias secos; isso mostra por que uma única métrica não é suficiente, mas também torna injustificável um modelo com viés positivo de quase 10 mm.

5.3 A regressão à média sob MSE comum

Um run histórico com MSE comum, `glstm_sweep_20260713_160748`, usa outra configuração e, portanto, não é uma ablação perfeitamente controlada. Ele serve para mostrar o mecanismo clássico: quando a perda volta a ser MSE e o sinal desaparece, a constante deixa de ser 15 mm e volta à média de aproximadamente 4–5 mm.

Lead	$\bar{y}$	$\hat{\bar{y}}$	$s_{\hat{y}}/s_y$	Corr.	R^2
D+1	4,806	4,321	0,394	0,429	0,181
D+2	4,817	4,053	0,151	0,177	0,026
D+3	4,824	4,027	0,102	0,112	0,007
D+4	4,828	4,108	0,076	0,092	0,004
D+5	4,831	4,154	0,065	0,094	0,004




Figura 2: Run histórico com MSE. Em D+5, a saída laranja converge para a média comum e quase não varia. A loss atual muda a altura da linha, mas não resolve a falta de dispersão.

6 Por que a loss produz uma média ponderada

6.1 Derivação

Para uma constante c e MSE ponderada,

$$L(c) = \frac{\sum_i w_i (c - y_i)^2}{\sum_i w_i}, \quad \frac{\partial L}{\partial c} = 0 \implies c^* = \frac{\sum_i w_i y_i}{\sum_i w_i}.$$

Na forma condicional, o regressor ótimo é

$$f^*(x) = \frac{\mathbb{E}[w(Y)Y \mid X = x]}{\mathbb{E}[w(Y) \mid X = x]}.$$

Se X informa pouco sobre o futuro, $f^*(x)$ varia pouco e se aproxima do centroide global. Em MSE comum, $w = 1$ e esse centroide é a média. Na loss atual, os pesos são construídos em `src/Training/experiment_runner.py:169–src/Training/experiment_runner.py:235`:

- 90% inferiores: peso 0,199995, média 1,902 mm;
- 10% superiores ao Q90: peso 1,800005, média 28,681 mm.

Cada extremo recebe cerca de nove vezes o peso de um caso comum. Como há nove vezes mais casos comuns, os dois grupos recebem aproximadamente a mesma massa total. O ótimo constante torna-se

$$c^* \approx \frac{1,902 + 28,681}{2} = 15,291 \text{ mm}.$$

É exatamente a região para a qual D+2–D+5 convergem. O nome `quantile_mse` pode induzir a interpretação errada: ele **não** estima o quantil 0,9. Para isso seria necessária pinball loss. Ele estima uma média condicional reponderada.

6.2 A seleção do checkpoint reforça o desalinhamento

O early stopping e o scheduler usam a mesma loss ponderada. No run atual:

Estado	Época	Val loss	Val MSE pad.	Val R^2
Primeira época	1	2,7769	1,9263	-0,898
Melhor MSE/ R^2 ordinário	6	2,7365	1,7674	-0,739
Checkpoint pela loss configurada	13	2,7121	1,9842	-0,952
Última época registrada	24	2,7204	1,9869	-0,954

A loss ponderada melhora, enquanto o R^2 físico piora. O otimizador está fazendo o que foi pedido. O problema é que o critério de seleção não corresponde ao comportamento que se deseja avaliar.




Figura 3: R^2 ordinário negativo em treino e validação no run atual. Não há o padrão principal de overfit clássico; o objetivo monitorado é outro.

7 O grafo aprendível está promovendo oversmoothing

7.1 Mecanismo no código

Em `src/Models/model.py:139–src/Models/model.py:187`, uma não-aresta é representada por probabilidade 10^{-4} , isto é, logit aproximadamente $-9,21$. Com `LOCK_TOPOLOGY=False`, todas as 3.624 não-arestas entram no vetor de parâmetros.

O treino separa `a_logits` apenas para permitir outro learning rate, mas cria o Adam com o mesmo `weight_decay` para todos os grupos (`src/Training/Training_Routines.py:126–src/Training/Training_Routines.py:145`). L2 leva logits para zero. Para uma aresta probabilística, isso não é esparsidade:

$$a_{ij} \rightarrow 0 \implies \sigma(a_{ij}) \rightarrow 0,5.$$

Depois de cada passo, os logits também são truncados em $[-6, 6]$ (`src/Training/Training_Routines.py:226–src/Training/Training_Routines.py:229`). O primeiro clamp sozinho eleva uma não-aresta de 10^{-4} para $\sigma(-6) = 0,00247$, cerca de 25 vezes.


7.2 Evidência no checkpoint

Componente da adjacência	Inicial	Checkpoint
Probabilidade média nas 158 arestas dirigidas KNN	0,9500	0,5433
Probabilidade média nas 3.624 não-arestas	0,0001	0,09049
Massa normalizada em self-loops	—	13,05%
Massa normalizada nas arestas KNN	—	17,87%
Massa normalizada nas não-arestas	—	69,04%
Segundo autovalor em módulo $ \lambda_2 $	—	0,2823
Proxy $ \lambda_2 ^{35}$	—	$\approx 6 \times 10^{-20}$

O proxy espectral não é uma igualdade para a GLSTM, porque gates e transformações não lineares intervêm. Ele mostra, contudo, quão rapidamente a propagação espacial pura apagaria componentes

não constantes. Isso é relevante porque $H_{\text{prev}} @ A$ e $C_{\text{prev}} @ A$ são aplicados em cada passo da célula (`src/Models/model.py:197–src/Models/model.py:215`) e o loop tem 35 passos (`src/Models/model.py:277–src/Models/model.py:280`).

A dispersão espacial média no alvo é 4,13 mm; ela cai para 1,25 mm no modelo com grafo aprendível e 1,56 mm no par com grafo fixo. Em uma comparação quase controlada, `glstm_sweep_20260715_103451` (grafo fixo) obteve $R^2 = -0,747$, enquanto o run atual aprendível obteve $-0,803$. Logo, o grafo não é a causa única, mas piora a homogeneização.



Inicial: KNN forte e não-arestas próximas de zero.

Final: arestas originais enfraquecidas e fundo denso de baixa intensidade.

Figura 4: Adjacência não normalizada antes e depois do treinamento. A escala visual escura torna os pesos 0,09 discretos, mas a quantidade de não-arestas faz sua massa dominar.

8 Limitação informacional e arquitetural

8.1 O input não é uma previsão meteorológica de $D+1-D+5$

As 25 features são agregados diários históricos de precipitação, temperatura/ponto de orvalho, umidade específica e velocidade vertical. `INCLUDE_WIND=False`. Não há:

- campos NWP previstos para cada lead;
- seno/cosseno de dia do ano ou mês;
- latitude, longitude, altitude ou embedding persistente da estação;
- índices de circulação, pressão à superfície, CAPE ou umidade integrada configurados no run atual;
- direção espacial da advecção; o grafo é estático e simétrico.

O catálogo contém altitudes de 0 a 1.228,59 m, porém `src/Data/feature_extraction.py:454–src/Data/feature_extraction.py:467` retém somente latitude e longitude, e estas nem sequer entram como feature do modelo. O tempo permanece em xarray como coordenada, mas é descartado na fronteira Torch. Assim, a rede precisa inferir sazonalidade e orografia apenas pelas séries passadas.

Uma verificação univariada confirma o rápido desaparecimento do sinal: a persistência da última chuva observada tem correlação 0,220 com $D+1$ e 0,042 com $D+5$. A maior correlação absoluta entre

qualquer feature no fim da janela e o alvo foi 0,288 em D+1 e 0,049 em D+5. Relações não lineares podem existir, mas esses valores explicam por que um regressor determinístico se apoia no centroide para leads longos.

8.2 Head direto e gargalo comum

Em `src/Models/model.py:253–src/Models/model.py:281`, o último estado oculto de cada nó passa por um MLP que produz os cinco leads de uma vez. Não há decoder temporal, embedding de lead, mecanismo autoregressivo ou covariável futura. A mesma representação deve servir simultaneamente D+1 e D+5.

Isso produz a sequência observada: correlação 0,363 e razão de desvios 0,614 em D+1, mas correlação 0,120 e razão 0,166 em D+5. Mesmo sob MSE simples, D+5 conserva somente 6,5% do desvio real. Aumentar hidden de 32 para 256, mantendo uma configuração próxima, não resolveu (R^2 passou de $-0,747$ para $-0,776$). Capacidade bruta não substitui informação e um objetivo adequado.

8.3 A natureza de uma previsão pontual

Mesmo um regressor MSE correto estima $\mathbb{E}[Y | X]$, não uma realização aleatória de Y . Portanto, sua série deve ser mais suave que a observada. O problema aqui não é a mera existência de suavização; é sua magnitude e sua falta de skill: inclinações próximas de zero, R^2 negativo e desempenho inferior a climatologias de treino.

Para precipitação zero-inflada e de cauda longa, uma previsão distribucional ou em duas partes é mais informativa que forçar um único valor a representar simultaneamente ocorrência, volume e extremos.

9 Problemas secundários e observabilidade

Achado	Impacto
KNN em graus	<code>graph_related_utils.py:250–278</code> usa distância euclidiana em [longitude, latitude], sem Haversine nem peso por distância. Com $k = 2, 7$ de 62 nós mudam de vizinho em relação ao KNN geodésico; as arestas chegam a 150,9 km.
Nós duplicados	As 62 coordenadas de estação mapeiam para apenas 60 células ERA5 de 0,25 grau. BAGE/BAGE-CENTRO e CHARQUEADAS/PARQUE ELDORADO têm séries idênticas, embora sejam nós separados.
Scaler global do alvo	<code>temporal_dataset.py:529–550</code> usa <code>reshape(-1,1)</code> para todas as estações e leads. Se o sinal se perde, zero padronizado volta diretamente à média global, não a uma climatologia específica do nó/estação.
Unidades stale	A precipitação é multiplicada por 1.000 em <code>feature_extraction.py:438–443</code> , mas o Zarr diário ainda declara unidade “m”; temperatura é convertida a graus Celsius, enquanto o cache ainda pode declarar “K”. Os valores usados no run são coerentes com mm/°C, mas o metadado cria risco de dupla conversão futura.

Achado	Impacto
Métricas em escalas diferentes	<code>test_metrics.json</code> mede loss/MSE/MAE no alvo padronizado; os CSVs posteriores são inversamente transformados para mm. O nome das métricas não carrega a unidade.
MAPE sem interpretação	Com muitos zeros, MAPE físico já é instável. No treino atual ele é calculado sobre o alvo padronizado; zero significa “igual à média do treino”, não “sem chuva”. O valor 476,97% não deve orientar seleção.
Média por batch	Loss, MSE e MAE são promediadas por número de batches, não pelo número de elementos. O último batch menor recebe peso excessivo. O R^2 global usa acumuladores corretos.
Resumo versus checkpoint	<code>run_summary.json</code> guarda várias métricas da última época, mas <code>model_state_dict.pt</code> guarda o melhor checkpoint pela loss. As duas linhas não descrevem necessariamente o mesmo modelo.
Datas nulas no resumo	Os DataLoaders usam <code>TensorDataset</code> ; por isso <code>train_start_date</code> , <code>train_end_date</code> e equivalentes saem nulos, embora as datas ainda existam em <code>dataset_contract.json</code> .
Sem diagnóstico de clipping	O retorno de <code>clip_grad_norm</code> é descartado. Não se sabe em quantos batches o limite 1 está efetivamente reduzindo o gradiente.

10 Hipóteses descartadas ou rebaixadas

- **Leakage/target deslocado:** não confirmado; as datas e shapes estão corretos e os alvos de cada split são disjuntos.
- **NaN/Inf:** não confirmado nos dados atuais.
- **Drift como causa dominante:** rebaixado; treino e teste têm estatísticas próximas, e o treino também apresenta R^2 negativo.
- **Overfit clássico do default:** rebaixado; loss de treino e validação são próximas. Há runs históricos maiores com gap treino–validação, mas esse não é o padrão principal do run atual.
- **Normalização do target como causa isolada:** rebaixada; ablações com e sem normalização permanecem ruins. O problema é o objetivo, o sinal e a arquitetura espacial.
- **Poucos parâmetros apenas:** rebaixado; hidden 256 não trouxe ganho. Um modelo maior pode memorizar treino sem resolver a transferência temporal.

11 Plano recomendado

11.1 Prioridade P0 — tornar a conclusão mensurável

Antes de nova arquitetura, o runner deve produzir em todo run:

1. baselines ajustados somente no treino: zero, média global, média por estação, climatologia estação–mês e persistência no fim da janela;
2. métricas físicas por lead, estação, estação do ano e regime de chuva: MSE, RMSE, MAE, R^2 , viés, correlação, inclinação e $s_{\hat{y}}/s_y$;

3. classificação para limiares como 0,1, 1, 10 mm, Q90 e Q95: precisão, recall, FAR, CSI e Brier score quando houver probabilidade;
4. datas exatas dos splits, scaler completo, unidade de cada artefato, melhor época em cada métrica e norma pré-clipping;
5. gráficos da massa em arestas/não-arestas, grau efetivo, $|\lambda_2|$ e variância espacial por época.

11.2 Prioridade P1 — separar objetivo, horizonte e grafo

Executar uma matriz controlada, mesma seed, mesmo split e mesmos dados:

Teste	Horizonte	Grafo	Objetivo
A0	—	—	Climatologia estação-mês
A1	D+1	Sem grafo	MSE comum
A2	D+1	KNN Haversine fixo	MSE comum
A3	D+1	Topologia KNN travada	MSE, adjacência aprendível sem decay nos logits
A4	D+1–D+5	Melhor opção A1– A3	Um modelo separado por lead ou decoder com embedding de lead
A5	D+1–D+5	Melhor grafo	Pinball verdadeira para quantis explícitos
A6	D+1–D+5	Melhor grafo	Ocorrência + quantidade positiva/distribuição

Não avançar para D+5 antes de obter skill reproduzível em D+1. Um teste adicional deve fazer a rede memorizar deliberadamente 16–32 janelas, sem dropout, weight decay, AMP ou grafo aprendível. Se ela não levar a loss quase a zero, existe um problema de capacidade/gradiente separado da generalização.

11.3 Prioridade P1 — corrigir o grafo aprendível

- usar `LEARN_ADJ=False` como baseline obrigatório;
- quando aprender pesos, começar com `LOCK_TOPOLOGY=True`;
- definir `weight_decay=0` especificamente para `a_logits`;
- substituir L2 nos logits por penalidade de esparsidade sobre probabilidades off-diagonal, top- k ou orçamento de massa explícito;
- não usar clamp incompatível com a probabilidade inicial 10^{-4} ; ou inicializar de modo coerente com o intervalo permitido;
- comparar KNN Haversine ponderado por distância e grafo dirigido/dinâmico informado por vento;
- testar mistura espacial residual uma vez por bloco, em vez de difusão total do estado de célula em todos os passos.

Um teste unitário conceitual deve executar um passo sem gradiente informativo e confirmar que uma não-aresta não cresce apenas por weight decay/clamp. O comportamento atual falha nesse critério.

11.4 Prioridade P2 — fornecer informação realmente preditiva

- incluir seno/cosseno de dia do ano e, se apropriado, hora/estação;

- incluir latitude, longitude, altitude e/ou embedding de nó;
- habilitar e validar vento, preferencialmente de modo direcional;
- para previsão D+1–D+5, fornecer covariáveis NWP válidas em cada lead, não somente observações históricas;
- considerar previsão residual sobre climatologia ou NWP, preservando um caminho de skip;
- se o alvo final for estação INMET, treinar e avaliar contra observação INMET, com ERA5 como covariável, não como substituto silencioso do alvo.

11.5 Prioridade P2 — objetivo adequado à precipitação

Há três perguntas distintas e elas não devem ser misturadas em uma única MSE ponderada:

1. **Vai chover?** Classificação/probabilidade de ocorrência.
2. **Quanto, dado que chove?** Distribuição positiva, por exemplo Gamma/lognormal, ou uma família como Tweedie quando apropriada.
3. **Qual o risco de extremo?** Quantis com pinball loss ou probabilidade de exceder limiares, avaliada com métricas probabilísticas.

Softplus não deve ser aplicado diretamente a um alvo padronizado que possui valores negativos. A transformação e a distribuição precisam ser definidas de forma consistente. Uma saída determinística pode permanecer como baseline, mas deve ser comparada à climatologia e não ser tratada como amostra realista da chuva.

11.6 Critérios de aceitação

Uma modificação só deve ser considerada melhoria se:

- superar climatologia estação–mês no mesmo bloco temporal, por lead;
- manter viés e razão de desvios reportados, evitando ganho aparente por previsão constante;
- repetir o ganho em múltiplas seeds e janelas rolling-origin;
- para a GNN, superar o mesmo modelo sem grafo sob idênticas condições;
- se a alegação incluir novas estações, superar um holdout espacial explícito;
- preservar esparsidade/massa do grafo dentro de limites definidos antes do treino;
- reportar separadamente skill em seco, chuva moderada e extremos.

12 Resposta direta

O modelo converge para a média porque uma previsão pontual por erro quadrático escolhe o centro condicional quando não consegue distinguir os futuros possíveis. No GLSTM atual, essa tendência é amplificada por quatro fatos concretos:

1. o histórico contém pouco sinal para chuva exata em D+2–D+5 e não há preditores futuros;
2. os cinco leads saem do mesmo estado oculto final, cuja variabilidade diminui com o lead;

3. o grafo aprendível torna-se quase global e mistura os nós repetidamente;
4. a loss atual troca a média comum de 4,58 mm por uma média ponderada de 15,29 mm.

Por isso, com MSE comum vê-se uma linha próxima de 4–5 mm; com `quantile_mse`, vê-se uma linha próxima de 14–15 mm. O fenômeno é o mesmo: pouca dependência de X e grande dependência do centroide imposto pela função objetivo.

Síntese final. O primeiro passo não é aumentar a rede. É alinhar objetivo e métrica, desativar a adjacência livre, provar skill em D+1 contra climatologia e adicionar informação futura/estática. Só depois faz sentido reintroduzir um grafo aprendível e o horizonte completo.

A Trilha de evidências reproduzíveis

Artefato	Uso nesta auditoria
<code>.../120845/config.json</code>	Configuração efetiva do run atual.
<code>.../120845/dataset_contract.json</code>	Shapes, features, estações e cobertura temporal.
<code>.../120845/run_summary.json</code>	Pesos/limiar da loss, épocas, loss e R^2 registrados.
<code>.../120845/hist.pt</code>	Localização das melhores épocas por loss e por MSE/ R^2 .
<code>.../120845/model_state_dict.pt</code>	Probabilidades e espectro da adjacência do checkpoint.
<code>.../120845/test_predictions_by_lead_day.csv</code>	Distribuições, correlação, inclinação, viés e métricas físicas.
<code>.../120845/forecast_horizon_diagnostics/test_prediction_metrics_by_lead_day.csv</code>	Conferência das métricas físicas por lead.
<code>.../160748/test_predictions_by_lead_day.csv</code>	Evidência histórica do colapso à média sob MSE comum.
<code>Datasets/processed/daily/precipitation_daily.zarr</code>	Reconstrução de distribuição de treino e baselines sem usar o teste para ajuste.

B Limitações da auditoria

- As comparações identificadas como históricas usam hiperparâmetros diferentes e não são apresentadas como efeito causal isolado.
- Correlações univariadas não excluem relações não lineares; elas medem a dificuldade e a perda progressiva de sinal, não uma impossibilidade matemática.
- Os totais diários ERA5 não foram confrontados com uma fonte meteorológica independente nem com pluviômetros INMET nesta auditoria.
- Não foi implementada uma correção funcional. O documento registra o diagnóstico e uma sequência de experimentos capaz de separar as causas.